

Classificação de Ferrugem Asiática da Soja por Redes Neurais Convolucionais

Guilherme Henrique Rodrigues^{1*}; Hugo Bampi²

^{1*} Cientista da Computação. E-mail autor correspondente: guilherme.rodriguesft@gmail.com

² Mestre. E-mail: hugobampi@gmail.com

Classificação de Ferrugem Asiática da Soja por Redes Neurais Convolucionais

Resumo (ou Sumário Executivo)

A ferrugem asiática (*Phakopsora pachyrhizi*) é uma das principais ameaças à produtividade da soja, e seu diagnóstico precoce depende de inspeção manual trabalhosa e sujeita a variabilidade entre avaliadores. Este trabalho avaliou Redes Neurais Convolucionais para a classificação binária de imagens de folhas de soja entre os estados saudável e infectado por ferrugem, com ênfase na capacidade de generalização entre conjuntos de dados de origens distintas. Os modelos foram treinados sobre imagens de campo do conjunto ASDID e avaliados tanto em um teste interno controlado quanto em um conjunto independente da Embrapa (PDDB), adquirido sob protocolo distinto. Para evitar vazamento de dados e correlações falsas entre classe e condições de captura, adotou-se particionamento por data de aquisição e teste restrito a sessões contendo ambas as classes. As arquiteturas ResNet-18 e ResNet-50 ajustadas de ponta a ponta atingiram F1 de 0,954 no teste controlado e preservaram desempenho elevado no teste independente (AUC-ROC de 0,978 e 0,926, respectivamente), com análises de interpretabilidade indicando que a decisão se apoia em tecido sintomático, e não em artefatos de fundo.

Palavras-chave: Aprendizado profundo; Transfer learning; Generalização entre domínios; Interpretabilidade de modelos; Agricultura de precisão.

Introdução

A soja (*Glycine max* (L.) Merr.) encontra-se entre as culturas de maior relevância econômica para o Brasil, respondendo por parcela expressiva das exportações do agronegócio nacional. Sua produtividade, contudo, é recorrentemente ameaçada por doenças foliares, com destaque para a ferrugem asiática, causada pelo fungo biotrófico *Phakopsora pachyrhizi* Sydow & P. Sydow. Identificada no país na safra 2001/2002, a doença pode ocasionar perdas de até 90% na produtividade quando não manejada adequadamente (Embrapa Soja, 2023).

O diagnóstico precoce da ferrugem asiática é determinante para a adoção de medidas de controle eficazes, como a aplicação de fungicidas em janela apropriada. O monitoramento convencional, entretanto, depende de inspeção manual por técnicos e fitopatologistas — processo trabalhoso, custoso e sujeito a variabilidade entre avaliadores. Nesse cenário, sistemas automatizados de detecção baseados em visão computacional e aprendizado profundo (LeCun et al., 2015) apresentam-se como alternativa promissora para agilizar e democratizar o diagnóstico fitossanitário.

As Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*) consolidaram-se como uma das abordagens mais eficazes para a classificação de imagens na agricultura de precisão. Estudos recentes relatam que arquiteturas como AlexNet, VGG, ResNet e GoogLeNet alcançam acurácias superiores a 90% na classificação de doenças foliares em diversas culturas (Shoaib et al., 2022; Bevers et al., 2022). No contexto específico da soja, modelos de aprendizado profundo têm se diferenciado, com alta confiabilidade, folhas saudáveis daquelas infectadas por distintos patógenos (Wu et al., 2024; Feng et al., 2024).

Um aspecto pouco explorado nesses trabalhos é a capacidade de generalização dos modelos para imagens adquiridas em condições diferentes das do treinamento. Modelos treinados e avaliados sobre um único conjunto podem aprender artefatos de aquisição — fundo, iluminação, câmera ou estágio fenológico — em vez dos sintomas da doença, inflando o desempenho aparente. A avaliação sobre conjuntos independentes (*cross-dataset*) é, portanto, essencial para estimar a utilidade prática do classificador. Neste trabalho, os modelos foram treinados sobre imagens de campo do conjunto ASDID (Bevers et al., 2022) e avaliados de forma independente sobre o conjunto PDDb, disponibilizado pela Embrapa no repositório REDAPE (Embrapa, 2024), cujas imagens foram adquiridas sob protocolo distinto.

Diante do exposto, este trabalho tem como objetivo desenvolver e avaliar modelos de Redes Neurais Convolucionais, implementados em PyTorch, para a classificação binária de imagens de folhas de soja entre os estados saudável e infectado por ferrugem asiática (*Phakopsora pachyrhizi*), contemplando duas estratégias de modelagem — o ajuste fino de redes pré-treinadas de ponta a ponta e o uso de extratores de características congelados associados a classificadores clássicos — e enfatizando a avaliação da capacidade de generalização entre conjuntos de dados e a interpretabilidade das predições.

Metodologia

A pesquisa caracterizou-se como experimental, de natureza aplicada e abordagem quantitativa, conduzida integralmente em ambiente computacional, sem envolvimento de seres humanos ou coleta de dados primários em campo.

Conjuntos de dados

Foram utilizados dois conjuntos de dados de origens independentes. O treinamento, a validação e o ajuste de hiperparâmetros basearam-se no conjunto ASDID (Bever et al., 2022), composto por imagens de campo de folhas de soja saudáveis e infectadas por ferrugem asiática. O conjunto Pddb (Embrapa, 2024), cujas imagens foram adquiridas sob protocolo distinto — folhas dispostas sobre placa de calibração de cor —, foi reservado exclusivamente como conjunto de teste independente (*cross-dataset, out-of-distribution*), não sendo empregado em nenhuma etapa de treinamento ou de seleção de modelos. Em todas as métricas, considerou-se a classe infectada (*rust*) como classe positiva.

Pré-processamento e particionamento

As imagens foram redimensionadas para 224×224 pixels e normalizadas segundo as médias e os desvios-padrão do ImageNet, em conformidade com o uso de pesos pré-treinados nesse conjunto (Deng et al., 2009). Apenas ao subconjunto de treinamento aplicaram-se técnicas de data augmentation (espelhamento horizontal, rotações, variações de brilho e recortes aleatórios), preservando-se validação e teste sem aumento. A inspeção dos metadados EXIF (*Exchangeable Image File Format*) do ASDID revelou que as imagens foram adquiridas em sessões de captura — rajadas de poucos minutos em uma mesma data — e que a classe estava fortemente correlacionada com a data de aquisição. Para evitar vazamento de dados entre partições e a aprendizagem das condições de captura como atalho, o particionamento foi realizado por data de aquisição, garantindo que nenhuma sessão fosse compartilhada entre treinamento, validação e teste. O teste interno foi ainda restrito às datas em que ambas as classes foram fotografadas na mesma sessão (dias mistos), nas quais as condições de captura são equivalentes entre as classes, isolando a doença como única diferença sistemática.

Arquiteturas e estratégias de modelagem

Avaliaram-se duas estratégias de modelagem. Na primeira (Abordagem 1), redes pré-treinadas no ImageNet foram ajustadas de ponta a ponta ao problema, atuando a própria CNN como classificador; consideraram-se as arquiteturas ResNet-18, ResNet-50 (He et al., 2016), VGG-16 e GoogLeNet. Na segunda (Abordagem 2), empregou-se uma rede pré-treinada como extrator de características fixo, cujos vetores resultantes alimentaram cinco classificadores clássicos: *Naive Bayes*, Regressão Logística, *Random Forest*, *Support Vector Machine* e *Perceptron* de múltiplas camadas. O treinamento da Abordagem 1 utilizou a função de perda de entropia cruzada e o otimizador Adam, com taxa de aprendizado inicial

de 1×10^{-3} ajustada por agendador de redução em platô e critério de parada antecipada (*early stopping*) monitorando a perda de validação.

Avaliação de desempenho

O desempenho foi avaliado em dois cenários: um teste interno controlado (dias mistos do ASDID) e o teste independente sobre o conjunto da Embrapa. Reportaram-se a acurácia, a acurácia balanceada, a precisão, o recall e o F1-score da classe infectada, além da AUC-ROC. Geraram-se matrizes de confusão e curvas ROC, e monitoraram-se as curvas de aprendizado (perda e acurácia por época) para detecção de sobreajuste e subajuste. Em razão do desbalanceamento entre classes, privilegiaram-se a acurácia balanceada, o F1-score e a AUC-ROC como métricas de referência, por serem mais informativas que a acurácia simples nesse contexto.

Interpretabilidade

Para verificar se as predições se apoiavam em sintomas da doença ou em atalhos espúrios, aplicaram-se três técnicas de interpretabilidade: Grad-CAM (Selvaraju et al., 2017), atribuição por SHAP (Lundberg & Lee, 2017) por meio do *GradientExplainer*, e análise de sensibilidade por oclusão (*occlusion sensitivity*). As duas primeiras aplicaram-se aos modelos diferenciáveis (CNNs ajustadas de ponta a ponta e à cabeça de regressão logística reconstruída sobre o extrator congelado), ao passo que a análise por oclusão, por ser independente do modelo, aplicou-se a ambas as abordagens.

Ferramentas e ambiente computacional

O desenvolvimento foi realizado em linguagem Python, com o framework PyTorch (Paszke et al., 2019) e a biblioteca *torchvision* para construção, treinamento e carregamento dos modelos e dos dados; *scikit-learn* para os classificadores clássicos e o cálculo das métricas; as bibliotecas SHAP e OpenCV para as análises de interpretabilidade e o pré-processamento de imagens; e matplotlib para a visualização dos resultados. Os experimentos foram executados em máquina local equipada com GPU NVIDIA (CUDA).

Resultados Preliminares

Esta seção apresenta os resultados obtidos até o presente estágio do trabalho. Foram avaliadas duas arquiteturas convolucionais — *ResNet-50* e *ResNet-18* — sob a abordagem de *fine-tuning end-to-end* (Abordagem 1), na qual a rede pré-treinada no ImageNet é integralmente ajustada ao problema e a própria CNN atua como classificador. A abordagem baseada em extrator de características congelado seguido de classificadores clássicos (*Naive Bayes*, Regressão Logística, *Random Forest*, SVM e MLP — Abordagem 2), bem como as arquiteturas VGG-16 e GoogLeNet, serão avaliadas em etapa posterior. As análises de interpretabilidade (*occlusion sensitivity*) também serão incorporadas em momento subsequente.

Protocolo experimental

O treinamento foi conduzido sobre o conjunto ASDID (Bever et al., 2022), composto por imagens de campo de folhas de soja saudáveis e infectadas. O conjunto independente da Embrapa (PDDb), adquirido sob protocolo distinto — folhas dispostas sobre placa de calibração de cor — foi reservado exclusivamente como teste cross-dataset, nunca sendo utilizado em treinamento, validação ou ajuste de hiperparâmetros. A classe positiva para todas as métricas de precisão, recall e F1 é a classe doente (*rust*).

A inspeção dos metadados ASDID revelou dois fatos determinantes para o desenho experimental. Primeiro, as imagens foram adquiridas em sessões de captura (fotografias tiradas com poucos minutos de diferença numa mesma data), de modo que uma divisão aleatória por imagem colocaria fotografias da mesma sessão simultaneamente em treino e teste, configurando vazamento de dados e métricas superestimadas. Segundo, a classe está fortemente correlacionada com a data de captura, onde das 17 datas identificadas, 11 contêm predominantemente uma única classe. Isso implica que um modelo poderia atingir alta acurácia reconhecendo as condições do dia (iluminação e câmera) em vez dos sintomas da doença.

Para mitigar ambos os problemas, adotou-se: (i) divisão por data de captura (group split pela data), garantindo que nenhuma sessão atravessasse as partições de treino, validação e teste; e (ii) teste *in-distribution* restrito aos "dias mistos" — as quatro datas em que ambas as classes foram fotografadas na mesma sessão (totalizando 774 imagens; 464 saudáveis e 310 infectadas). Nesses dias, as condições de captura são idênticas entre as classes, de forma que a única diferença sistemática entre folhas saudáveis e infectadas é a própria doença. O desempenho nesse conjunto, portanto, mede discriminação de sintomas sem uma possível interferência de datas de captura.

Dada a presença de desbalanceamento entre classes, a acurácia simples é reportada por completude, mas as métricas de referência adotadas são a acurácia balanceada, o F1 da classe doente, e a AUC-ROC, mais informativas sob desbalanceamento.

Desempenho dos modelos

A Tabela 1 resume o desempenho das duas arquiteturas no teste *in-distribution* controlado (dias mistos do ASDID) e no teste cross-dataset (Embrapa/PDDDB).

Tabela 1 — Desempenho das arquiteturas ResNet-50 e ResNet-18 (Abordagem 1).

Métrica	ResNet-50 (controlado)	ResNet-18 (controlado)	ResNet-50 (Embrapa)	ResNet-18 (Embrapa)
Acurácia	0,964	0,965	0,811	0,905
Acurácia balanceada	0,959	0,956	0,892	0,946
Precisão (<i>rust</i>)	0,973	1,000	1,000	1,000
Recall (<i>rust</i>)	0,935	0,913	0,785	0,892
F1 (<i>rust</i>)	0,954	0,954	0,879	0,943
AUC-ROC	0,980	0,999	0,926	0,978

No teste *in-distribution* controlado, ambas as arquiteturas apresentaram desempenho elevado e praticamente equivalente em F1 (0,954 para as duas), com AUC-ROC de 0,980 (ResNet-50) e 0,999 (ResNet-18). O resultado é o ponto central destes experimentos: mesmo com as informações da data de captura indisponível, os modelos separam folhas saudáveis de infectadas com alta confiabilidade, o que indica que a discriminação se apoia, ao menos em parte substancial, em características genuínas da doença, e não meramente em artefatos de aquisição.

No teste *cross-dataset* sobre o conjunto da Embrapa — adquirido de forma totalmente independente —, a capacidade discriminativa se preservou (AUC-ROC de 0,926 para a ResNet-50 e 0,978 para a ResNet-18). Como treino e teste provêm de bancos coletados independentemente, esse resultado é, por construção, imune às características de vazamento do ASDID, reforçando a evidência de que os modelos aprenderam o sintoma e não o protocolo de aquisição.

Figura 1 - Matriz de Confusão - Resnet-18





Figura 2 - Matriz de Confusão - Resnet-50



A análise da estrutura dos erros é relevante para a aplicação. Em ambos os modelos, a precisão da classe doente no conjunto da Embrapa foi de 1 — isto é, nenhuma folha saudável foi classificada como doente (zero falsos positivos). A totalidade do erro *cross-dataset* concentra-se em folhas infectadas classificadas como saudáveis, observando nas Figuras 1 e 2, temos que 7 de 65 classificadas como saudáveis quando infectadas na ResNet-18 e 14 de 65 na ResNet-50, o que corresponde à queda do recall da classe doente. Como a AUC-ROC permanece alta (0,93–0,98) enquanto o recall no limiar padrão é menor, parte dessa perda é atribuível a uma diferença de calibração do limiar entre os domínios, e não a uma incapacidade de separação — sugerindo que o ajuste do limiar de decisão sobre um conjunto de validação poderia recuperar sensibilidade no domínio da Embrapa.

Quanto à comparação entre arquiteturas, as duas redes foram equivalentes no teste *in-distribution* controlado, mas a ResNet-18 generalizou melhor para o domínio da Embrapa

em todas as métricas (F1 de 0,943 contra 0,879; recall de 0,892 contra 0,785; AUC-ROC de 0,978 contra 0,926). Uma hipótese é que a maior capacidade da ResNet-50 favoreça o sobreajuste às particularidades do conjunto de treino confundido, prejudicando a transferência.

Interpretabilidade

Para avaliar se o desempenho decorre do reconhecimento de sintomas ou de atalhos (efeito Clever Hans), aplicaram-se Grad-CAM e atribuição por SHAP às predições, em folhas saudáveis e infectadas do conjunto controlado e nas folhas infectadas classificadas erroneamente no conjunto da Embrapa.

Figura 3 - SHAP no conjunto de teste classificação rust - Resnet-18





Figura 4 - SHAP no conjunto de teste classificação rust - Resnet-50



Nas folhas infectadas, tanto o Grad-CAM quanto o SHAP concentraram a relevância sobre o limbo foliar. O SHAP, em particular, acompanhou o padrão pontilhado das pústulas distribuídas pela superfície da folha, em ambas as arquiteturas (Figuras 3 e 4). As previsões corretas de ferrugem (probabilidade $\approx 0,96$ – $1,00$) apoiam-se, portanto, em regiões de tecido sintomático, e não no fundo da cena.

Nas folhas saudáveis, o Grad-CAM da classe predita localizou-se no interior do limbo, sem concentração sistemática sobre o fundo (vegetação ao redor), comportamento coerente com uma decisão baseada na folha. Cabe uma ressalva de leitura quanto aos mapas SHAP das folhas saudáveis: como cada mapa é normalizado pelo próprio percentil, sua aparência intensa não reflete magnitude absoluta; nessas imagens a probabilidade de ferrugem situou-se entre 0,00 e 0,01, de modo que a atribuição para a classe doente é de magnitude desprezível, ainda que espacialmente distribuída sobre a folha.

Figura 5 - Grad-CAM no conjunto de teste (erro de classificação) - Resnet-18





Figura 6 - Grad-CAM no conjunto de teste (erro de classificação) - Resnet-50



A análise dos erros no conjunto da Embrapa é a mais informativa. Inicialmente pensou que o fundo de placa de calibração — presente nas imagens da Embrapa e ausente no treino — pudesse atuar como atalho. Os mapas, contudo, não sustentam essa hipótese, já que nas folhas infectadas erroneamente classificadas como saudáveis, o Grad-CAM concentrou-se sobre o limbo foliar, e não sobre a placa, que permaneceu sem relevância atribuída (Figuras 5 e 6). Esses erros, portanto, não decorrem de um atalho de fundo, mas

de sub detecção de sintomas tênues ou esparsos, onde o modelo examina a folha e, diante de sinais pouco proeminentes, conclui erroneamente pela ausência de doença. Tal leitura é consistente com a estrutura dos erros no conjunto (ausência de falsos positivos, perda concentrada no recall da classe doente) e com a hipótese de descalibração do limiar entre domínios.

Em conjunto, os mapas reforçam a evidência das métricas: a discriminação entre folhas saudáveis e infectadas apoia-se em características associadas à doença, e não em artefatos de aquisição.

Limitações

O conjunto de teste da Embrapa contém apenas 9 imagens saudáveis, de modo que a precisão da classe doente (1,000) e demais estimativas associadas à classe saudável repousam sobre uma amostra reduzida e possuem intervalo de confiança amplo.

A correlação entre classe e data de captura observada no ASDID, embora mitigada pelo desenho experimental (divisão por data e teste em dias mistos), permanece presente no conjunto de treinamento, não se pode descartar inteiramente que o modelo tenha aprendido condições de captura úteis em conjunto com os sintomas.

As imagens do conjunto da Embrapa apresentam fundo de placa de calibração, ausente no conjunto de treino. Embora a análise de interpretabilidade indique que esse fundo não dirige os erros observados (a relevância concentra-se na folha), seu efeito ainda deve ser verificado de forma controlada por meio de segmentação (remoção de fundo), uma vez que a interpretabilidade se baseou em poucos exemplos.

Por fim, restam pendentes a Abordagem 2 (extrator congelado com classificadores clássicos) e as arquiteturas VGG-16 e GoogLeNet, bem como a extensão das análises de interpretabilidade a essas configurações, cuja convergência com as métricas constituirá a evidência final quanto à natureza das características aprendidas pelos modelos.

Considerações Finais

Os resultados parciais indicam que as Redes Neurais Convolucionais ajustadas de ponta a ponta distinguiram folhas de soja saudáveis das infectadas por ferrugem asiática com alta confiabilidade, mesmo sob um protocolo experimental desenhado para neutralizar o atalho da data de captura. A capacidade discriminativa preservou-se em um conjunto independente, adquirido sob protocolo distinto, e as análises de interpretabilidade concentraram a relevância sobre o tecido foliar sintomático, e não sobre o fundo das

imagens. Em conjunto, a evidência obtida até o momento sustenta a hipótese de que os modelos aprenderam características associadas à doença, e não artefatos do processo de aquisição.

Tais conclusões, contudo, são preliminares. Apoiam-se em um subconjunto de teste independente de tamanho reduzido para a classe saudável, e contemplam apenas a primeira das duas abordagens previstas. Sua confirmação depende das etapas em andamento: repetição com múltiplas sementes, para quantificar a variabilidade das estimativas; a avaliação da abordagem baseada em extrator de características congelado associado a classificadores clássicos, bem como das arquiteturas VGG-16 e GoogLeNet e um teste controlado de segmentação sobre as imagens da Embrapa, para descartar de forma definitiva o efeito do fundo. A convergência dessas análises determinará as conclusões finais quanto à natureza das características aprendidas e à aplicabilidade prática do classificador.

Agradecimento

Agradeço ao meu orientador e a todos os responsáveis pela realização do MBA pelo suporte fundamental. Estendo minha profunda gratidão à minha família e aos meus amigos pelo apoio incondicional durante a construção deste trabalho. .

Referências

Bever, N.; Sikora, E.J.; Hardy, N.B. 2022. Soybean disease identification using original field images and transfer learning with convolutional neural networks. *Computers and Electronics in Agriculture* 203: 107449.

Deng, J.; Dong, W.; Socher, R.; Li, L.-J.; Li, K.; Fei-Fei, L. 2009. ImageNet: a large-scale hierarchical image database. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 248-255.

Empresa Brasileira de Pesquisa Agropecuária – Soja [Embrapa Soja]. 2023. Ferrugem-asiática da soja: manejo e prevenção. Disponível em: <<https://www.embrapa.br/soja/ferrugem>>. Acesso em: 30 mar. 2026.

Empresa Brasileira de Pesquisa Agropecuária [Embrapa]. 2024. Plant Disease Database (PDDb). REDAPE – Repositório de Dados de Pesquisa da Embrapa. Disponível em: <<https://www.redape.dados.embrapa.br/dataset.xhtml?persistentId=doi:10.48432/XA1OVL>>. Acesso em: 30 mar. 2026.

Feng, J. et al. 2024. DC2Net: an Asian soybean rust detection model based on hyperspectral imaging and deep learning. *Plant Phenomics* 6: 0163.

He, K.; Zhang, X.; Ren, S.; Sun, J. 2016. Deep residual learning for image recognition. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, p. 770-778.

LeCun, Y.; Bengio, Y.; Hinton, G. 2015. Deep learning. *Nature* 521: 436-444.

Lundberg, S.M.; Lee, S.-I. 2017. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems* 30: 4765-4774.

Paszke, A. et al. 2019. PyTorch: an imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems* 32: 8024-8035.

Selvaraju, R.R.; Cogswell, M.; Das, A.; Vedantam, R.; Parikh, D.; Batra, D. 2017. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: *IEEE International Conference on Computer Vision (ICCV)*, p. 618-626.

Shoaib, M.; Hussain, T.; Shah, B.; Ullah, I.; Shah, S.M.; Ali, F.; Park, S.H. 2022. Deep learning-based segmentation and classification of leaf images for detection of tomato plant disease. *Frontiers in Plant Science* 13: 1031748.

Wu, Y. et al. 2024. A deep semantic network-based image segmentation of soybean rust pathogens. *Frontiers in Plant Science* 15: 1340584.